

Memory and Temperature

Hopfield Networks と Temperature Sampling

Hanoi 実験を読むための短い教科書

本ノートは、Ramsauer et al. の *Hopfield Networks is All You Need* と、Wu–Mirhoseini–Tambe の *On the Role of Temperature Sampling in Test-Time Scaling* を、発表で使う範囲に絞って整理する。前者は Transformer attention を連想記憶の検索として見る理論を与え、後者は test-time scaling をサンプル数だけでなく温度方向にも広げる。Hanoi 実験では、低温での反復的失敗と高温での回復を説明する足場になる。

1 二つの論文をつなぐ見方

LLM の推論を、次の二段階で見る。

- 内部では、attention が文脈中の情報・中間表現・プロトタイプを検索する。
- 出力では、logit 分布から次トークンをサンプリングし、推論軌道を進める。

Ramsauer et al. は第一の段階に理論的な言葉を与える。Transformer attention は、modern Hopfield network の更新則と対応する。つまり attention は単なる重み付き平均ではなく、記憶パターンへの連想検索として読める。

Wu et al. は第二の段階に焦点を当てる。同じモデル、同じ問題でも、温度を変えると生成される reasoning trace の集合が変わる。そのため、単一温度でサンプル数 K を増やすだけでは到達できない解が、別の温度で現れることがある。

論文	主対象	発表での役割
Hopfield Networks is All You Need	attention と連想記憶	失敗を attractor として語る
Temperature Sampling in TTS	温度と推論軌道	高温で別解法に届く可能性を語る

2 Modern Hopfield Network

古典的 Hopfield network は、記憶したパターンをエネルギーの局所最小点として持つ連想記憶モデルである。Ramsauer et al. の modern Hopfield network は、これを連続状態に拡張し、指数的な記憶容量と attention との対応を示した。

定義 2.1 (連想記憶としての検索). 記憶パターンを列ベクトルとして並べた行列を

$$X = (\xi_1, \dots, \xi_N) \in \mathbb{R}^{d \times N}$$

とする。状態 $x \in \mathbb{R}^d$ が与えられたとき、modern Hopfield update は

$$x^{\text{new}} = X \text{softmax}(\beta X^\top x)$$

で与えられる。ここで $\beta > 0$ は inverse temperature に相当し、内積 $X^\top x$ は状態 x と各記憶パターンの類似度を表す。

$\text{softmax}(\beta X^\top x)$ は、どの記憶パターンをどれだけ読むかを定める重みである。 β が大きいほど最も近い記憶に鋭く集中し、小さいほど複数の記憶を平均する。

定義 2.2 (エネルギーの形). 論文では、状態 x に対して log-sum-exp を含むエネルギーを考える。概念的には

$$E(x) = -\frac{1}{\beta} \log \sum_{i=1}^N \exp(\beta \xi_i^\top x) + \frac{1}{2} \|x\|^2 + \text{定数}$$

という形である。更新則はこのエネルギーを下げる方向の写像として理解できる。

定理 2.1 (Ramsauer et al. の主結果). *Modern Hopfield network* は、連想空間の次元に対して指数的に多くのパターンを保存でき、一回の更新で記憶を検索でき、*retrieval error* は指数的に小さくなる。また、その更新則は *Transformer* の *attention* と等価に解釈できる。

論文は energy minima を三種類に分ける。

固定点の型	意味
global averaging	多くのパターンの平均へ落ちる
metastable state	一部のパターン集合の平均へ落ちる
single-pattern state	ほぼ一つの記憶を検索する

3 Attention との対応

Transformer attention は、query Q , key K , value V に対して

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V$$

と書ける。これは、query と key の類似度を softmax で重みに変え、value の重み付き平均を返す操作である。

Modern Hopfield update

$$x^{\text{new}} = X \text{softmax}(\beta X^\top x)$$

と比べると、query が現在状態、key が検索対象、value が読み出される内容に対応する。したがって attention head は、文脈中のトークンや内部表現から、必要な記憶を検索する Hopfield 的な層として読める。

注意. この論文が直接主張しているのは、attention の数式が modern Hopfield update と対応することである。「LLM が本当に人間の記憶のように考えている」という主張ではない。発表では、attention を記憶検索として解釈できる、という範囲に留めるのがよい。

Hanoi へつなぐなら、正しい再帰解法を一つの安定した検索先、反復的な誤手順を別の安定した検索先として見る。低温で同じ誤手順に落ち続けるなら、それは出力分布上の高確率な局所軌道であり、内部表現としては spurious attractor のように振る舞っている、と説明できる。

4 Temperature Sampling と Test-Time Scaling

次に、出力トークンの選び方を見る。言語モデルは各時刻で logit z_i を出し、温度 $T > 0$ を使って

$$p_T(i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

から次トークンを選ぶ。

- $T \rightarrow 0$: 最大 logit のトークンに集中する。決定的で反復しやすい。
- $T = 1$: 元の確率分布に従う。
- $T > 1$: 分布が平らになり、低確率候補も選ばれやすくなる。

Test-time scaling (TTS) では、同じ問題に対して複数の reasoning trace を生成し、答えを選択・投票・検証する。単一温度なら

$$\mathcal{R}_{T,K} = \{r_1, \dots, r_K\}, \quad r_i \sim p_T(r \mid x)$$

のように、温度 T を固定して K 本の推論を生成する。

定理 4.1 (Wu et al. の主張). 単一温度でサンプル数 K を増やすだけでは、性能向上は無限には続かない。一方、異なる温度は異なる問題集合を解くため、温度方向に *scaling* すると、単一温度 TTS より広い *reasoning boundary* を探索できる。

論文は Qwen3 系列の複数サイズと、AIME 2024/2025, MATH500, LiveCodeBench, Hi-ToM などの reasoning benchmark で評価している。平均すると、温度方向の scaling は単一温度 TTS に対して追加の性能改善を与えた。さらに、multi-temperature voting により、複数温度を使う計算コストを抑える方法も提案している。

定義 4.1 (multi-temperature voting の考え方). 温度集合 $\mathcal{T} = \{T_1, \dots, T_m\}$ を用意し、各温度で少数の推論を生成する。

$$\mathcal{R} = \bigcup_{T \in \mathcal{T}} \{r_{T,1}, \dots, r_{T,k_T}\}.$$

得られた答えを集約し、多数決や検証器で最終答えを選ぶ。これは、サンプル数 K だけでなく温度軸にも計算資源を配る方法である。

5 Hanoi 実験での読み方

Hanoi では、低温で正答率が低く、高温で一部の N だけ正答率が上がることがある。この現象は、次のように読むと二つの論文を自然につなげられる。

- 低温では、モデルは高確率な定型手順を選び続ける。
- その定型手順が正しい再帰解法なら成功するが、誤った move loop なら失敗が固定化する。
- 高温では、次トークン選択が平らになり、別の reasoning trace に入る確率が上がる。
- その別軌道が正しい解法アトラクタに近ければ、正答率が回復する。

- ただし高すぎる温度では、軌道そのものが壊れ、合法手や一貫性が失われる。

この説明で重要なのは、高温を単なるノイズとして扱わないことである。Wu et al. の結果に従えば、温度は探索する推論経路の集合を変える操作である。また Ramsauer et al. の見方に従えば、attention は記憶・プロトタイプ・中間表現への検索として読める。

観測	Hopfield 的解釈	temperature 的解釈
同じ誤手順の反復	spurious attractor	低温で高確率軌道に固定
高温で正答率上昇	別 basin への遷移	異なる reasoning trace の探索
高温で崩壊	検索先が不安定化	分布が平らすぎて制御不能

発表での一言

Transformer attention は、modern Hopfield network と対応するため、記憶検索や attractor の言葉で解釈できる。一方、temperature sampling は、その内部表現から出力軌道を選ぶ段階で、どの reasoning trace を探索するかを変える。したがって Hanoi の高温回復は、「ノイズで偶然よくなった」というより、「低温で固定された誤った軌道から外れ、別の解法軌道に入った」可能性として話せる。

参考文献

1. Hubert Ramsauer et al., “Hopfield Networks is All You Need,” ICLR 2021. arXiv:2008.02217. <https://arxiv.org/abs/2008.02217>
2. Yuheng Wu, Azalia Mirhoseini, Thierry Tambe, “On the Role of Temperature Sampling in Test-Time Scaling,” arXiv:2510.02611, 2025. <https://arxiv.org/abs/2510.02611>